

MCDI503

EXPLORACIÓN INTELIGENTE PARA LA CIENCIA DE DATOS

AVANCE DEL PROYECTO FASE 1

Nombre integrante/s: Jennifer Nilo – Patricio Núñez

Curso: MCDI503

Fecha: 08-09-2026

Grupo: 8

I. Índice

Contenido

I.	Índice	2
II.	Introducción y contextualización.....	3
III.	Objetivo exploratorio, preguntas iniciales y alcance	3
IV.	Implementación inicial del EDA en notebook.....	3
V.	Documentación trazable de decisiones exploratorias	3
VI.	Reproducibilidad y coherencia técnica	3
VII.	Registro del proceso, supuestos y limitaciones	4
VIII.	Hallazgos exploratorios iniciales y referencias al notebook	4
IX.	Bibliografía	4

II. Introducción y contextualización

El proyecto analiza cómo varía la supervivencia entre los grupos representados en el conjunto Titanic, considerando sexo registrado, edad, clase, tarifa, puerto de embarque y contexto familiar. La versión utilizada contiene 891 registros y 15 variables y se obtiene directamente con Seaborn (Waskom, 2024). El caso permite integrar variables numéricas y categóricas, valores faltantes y comparaciones entre grupos, por lo que resulta pertinente para implementar un primer EDA reproducible (Universidad Andrés Bello [UNAB], 2026a). Su valor es descriptivo y metodológico, orienta decisiones posteriores, pero no permite atribuir causalidad.

III. Objetivo exploratorio, preguntas iniciales y alcance

El objetivo es caracterizar la estructura y calidad de los datos y describir las diferencias iniciales de supervivencia según las variables seleccionadas. El alcance comprende diagnóstico de calidad, análisis univariado y bivariado, creación de variables derivadas y síntesis de hallazgos. No incluye imputación definitiva, pruebas de hipótesis ni modelamiento predictivo. Las preguntas se trataron como guías de exploración y sus supuestos como hipótesis de trabajo, no como conclusiones anticipadas.

Código	Pregunta exploratoria	Variables principales
P1	¿Cómo cambia la supervivencia según sexo registrado y clase?	survived, sex, pclass
P2	¿La edad difiere entre quienes sobrevivieron y quienes no?	survived, age
P3	¿Qué relación descriptiva existe entre tarifa, clase y supervivencia?	fare, pclass, survived
P4	¿Viajar solo o con familiares se asocia con la supervivencia?	sibsp, parch, alone
P5	¿El puerto presenta diferencias de supervivencia al considerar la clase?	embark_town, pclass

Tabla 1. Preguntas exploratorias desarrolladas en el notebook

IV. Implementación inicial del EDA en notebook

El notebook combina celdas narrativas y código en una secuencia de carga, validación, diagnóstico, transformación, análisis e interpretación. Los datos se conservan en `titanic_raw` y el trabajo se realiza sobre copias, luego se construye `titanic_eda` con 12 columnas. Las secciones 12.1 a 12.5 responden las cinco preguntas mediante tablas y figuras, mientras las secciones 13 a 18 consolidan decisiones, trazabilidad y controles. Esta organización hace visible la cadena pregunta → acción → resultado → interpretación → cautela recomendada para análisis computacionales reproducibles (Rule et al., 2019).

V. Documentación trazable de decisiones exploratorias

La bitácora de la sección 13 registra diez decisiones. La Tabla 2 resume las que modificaron el flujo o condicionaron la interpretación, junto con el resultado intermedio producido.

Decisión	Justificación	Resultado intermedio
Conservar la fuente y trabajar sobre copias.	Mantener una referencia inalterada.	<code>titanic_raw</code> y <code>titanic</code> conservan 891 filas.
No eliminar 107 filas iguales ni imputar faltantes.	No existe identificador y el tratamiento depende de cada pregunta.	P2 usa 714 edades; P5 usa 889 puertos.
Usar una representación por concepto y excluir deck del análisis.	Evitar redundancias y limitar el efecto de 77,2 % de ausencia.	La vista analítica parte con 9 variables originales.
Derivar <code>family_size</code> , <code>family_context</code> y <code>age_group</code> .	Responder P2 y P4 con definiciones visibles y revisables.	Se obtienen 12 columnas sin perder filas.
Informar tasas con sus tamaños y separar asociación de causalidad.	Evitar porcentajes sin denominador e inferencias no respaldadas.	Las cinco respuestas incluyen <code>n</code> y cautelas.

Tabla 2. Decisiones principales y resultados intermedios

VI. Reproducibilidad y coherencia técnica

El flujo se ejecuta en Google Colab mediante “Ejecutar todas”, sin cargas manuales. Registra versiones de Python y librerías, valida dimensiones y esquema, conserva los datos de entrada y calcula los textos numéricos desde las salidas. Las transformaciones se documentan en las Tablas 9 y 10, las agrupaciones

se implementan de forma uniforme con pandas (McKinney, 2010; The pandas development team, 2026). El control final aprobó 10 de 10 verificaciones y confirmó que las cinco preguntas poseen evidencia ejecutada, en línea con prácticas básicas de reproducibilidad (Rule et al., 2019).

VII. Registro del proceso, supuestos y limitaciones

El proceso siguió seis etapas: validación de entrada, diagnóstico de calidad, preparación exploratoria, análisis univariado, comparaciones bivariadas y síntesis trazable. Cada fila se asumió como un registro de pasajero, aunque no existe un identificador que permita verificar su particularidad. No se supuso que los faltantes fueran aleatorios, age aporta 714 casos válidos y el puerto 889. family_size aproxima vínculos registrados, los tramos etarios son cortes operativos y los estratos pequeños de Queenstown limitan algunas comparaciones. Las asociaciones describen esta muestra y no se interpretan como efectos causales.

VIII. Hallazgos exploratorios iniciales y referencias al notebook

Pregunta	Hallazgo inicial	Evidencia y cautela
P1	96,8 % en female de 1. ^a clase frente a 13,5 % en male de 3. ^a .	Tabla 11 y Figura 3; no controla edad u otros factores.
P2	Mediana de 28 años en ambos resultados; 58,0 % en niñez y 26,9 % en 60+.	Tablas 12-13 y Figura 4; solo 714 edades válidas.
P3	En 1. ^a clase, mediana 77,96 en supervivientes y 44,75 en no supervivientes; en 3. ^a son próximas.	Tabla 14 y Figura 5; tarifa y clase están relacionadas.
P4	50,6 % con familiares frente a 30,4 % entre quienes viajaban solos.	Tabla 15 y Figura 6; es una aproximación del contexto familiar.
P5	En 1. ^a clase: Cherbourg 69,4 % y Southampton 58,3 %; en 3. ^a : 37,9 % y 19,0 %.	Tabla 16 y Figura 7; Queenstown contiene estratos pequeños.

Tabla 3. Síntesis de hallazgos, evidencia y cautelas interpretativas




Figura 1. Supervivencia observada según sexo registrado y clase

IX. Bibliografía

- McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56-61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Rule, A., Birmingham, A., Zuniga, C., Altintas, I., Huang, S.-C., Knight, R., Moshiri, N., Nguyen, M. H., Rosenthal, S. B., Pérez, F., & Rose, P. W. (2019). Ten simple rules for writing and sharing computational analyses in Jupyter Notebooks. PLOS Computational Biology, 15(7), e1007007. <https://doi.org/10.1371/journal.pcbi.1007007>
- The pandas development team. (2026). pandas.DataFrame.groupby. pandas documentation. <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.groupby.html>
- Universidad Andrés Bello. (2026a). EDA mínimo viable con el dataset tips: Notebook de implementación, Fase 1, MCDI503 [Material de curso no publicado].
- Waskom, M. L. (2024). seaborn.load_dataset. seaborn 0.13.2 documentation. https://seaborn.pydata.org/generated/seaborn.load_dataset.html